

Predicción de la Carga de Calefacción en Edificios mediante Regresión Lineal

Jacob Espejel Guiza ^{#1}

[#] Instituto Tecnológico y de Estudios Superiores de Monterrey

¹ A01712021@tec.mx

Resumen

El consumo energético en los edificios representa una fracción significativa en la demanda eléctrica global, por lo que estimar tempranamente sus necesidades térmicas resulta clave para el diseño arquitectónico eficiente en la construcción de un edificio. Este trabajo tiene como objetivo predecir la carga de calefacción (*heating load*) de un edificio a partir de ocho características arquitectónicas (compacidad relativa, áreas de superficie, pared, techo, altura, orientación y distribución/área del vidrio), utilizando el conjunto de datos público de *Energy Efficiency* (768 muestras). Se realizó un proceso completo de ETL: exploración, limpieza y transformación de los datos seguido de la implementación manual de un modelo de regresión lineal, entrenando mediante el enfoque de Gradiente Descendente. El modelo con Gradiente Descendente (25,000 iteraciones, tasa de aprendizaje 0.001) obtuvo, sobre el conjunto de prueba 20% de los datos, no vistos durante el entrenamiento, un Error Absoluto Medio de 2.18 y un Error Cuadrático Medio de 9.12 en un rango que va de 6.01 a 43.10 puntos y un (R^2) de 0.9123 puntos. Para complementar este enfoque, se implementó un modelo Random Forest mediante el framework *scikit-learn*, integrado en un pipeline de preprocesamiento para transformar las variables categóricas y conservar la reproducibilidad del experimento. Sobre el conjunto de prueba, Random Forest obtuvo un Error Absoluto Medio de 0.37, un Error Cuadrático Medio de 0.28 y un (R^2) de 0.9973. La comparación entre ambos modelos muestra que Random Forest representa con mayor precisión las relaciones no lineales e interacciones entre las características arquitectónicas, aunque con una menor interpretabilidad que la regresión lineal. En conjunto, los resultados muestran que la regresión lineal, construida íntegramente desde los fundamentos matemáticos, ofrece una aproximación interpretable, mientras que el modelo basado en framework proporciona un desempeño predictivo superior para la estimación de la demanda térmica en etapas tempranas del diseño arquitectónico.

Keywords: Eficiencia Energética, Regresión lineal, Random Forest, Gradiente Descendente, scikit-learn, Machine Learning

I. INTRODUCCIÓN

La eficiencia energética en edificios constituye una línea prioritaria de investigación debido a la elevada incidencia del sector edificado sobre el consumo energético y el impacto ambiental asociado. En particular, la predicción de la carga de calefacción y de enfriamiento en edificaciones residenciales resulta fundamental para apoyar decisiones de diseño orientadas a reducir la demanda energética desde etapas tempranas del proyecto.

La estimación temprana de estas cargas es relevante para el diseño de sistemas, la evaluación del desempeño energético y la formulación de estrategias arquitectónicas más sostenibles.

A. Relevancia Arquitectónica

Desde una perspectiva arquitectónica, el comportamiento energético de un edificio depende en gran medida de sus atributos físicos y geométricos. Diversos estudios coinciden en que variables como la compacidad relativa, el área de superficie, el área de muros y cubierta, la altura, la orientación, y las características del acristalamiento influyen directamente sobre la carga térmica (Sajjad et al., 2020).

Estudios comparativos han identificado que la compacidad relativa y la altura general figuran entre las variables más influyentes sobre las cargas de calefacción y enfriamiento. De manera complementaria, configuraciones más compactas y simétricas tienden a presentar menores consumos energéticos que morfologías más alargadas o articuladas (Hindasi et al., 2026).




Fig. 1. Flujo metodológico del estudio.

1) *Simulación y Modelos Predictivos*: Tradicionalmente, la evaluación del desempeño térmico de los edificios se ha realizado mediante simulaciones energéticas dinámicas, la cual permite representar con alto nivel de detalle el efecto de múltiples variables de diseño sobre el consumo energético. Sin embargo, este enfoque suele requerir información detallada, capacidad computacional y conocimiento técnico especializado, lo que dificulta su uso ágil en fases preliminares del diseño.

Frente a esta limitación, los modelos basados en aprendizaje automático se han consolidado como una alternativa eficiente para aproximar la relación entre variables arquitectónicas y demanda térmica a partir de datos previos de simulación o medición. Reportes nos muestran que estos enfoques pueden alcanzar niveles altos de precisión y, además, reducir de forma importante los tiempos de cómputo en comparación con simulaciones exhaustivas.

2) *Conjunto de Datos*: Un referente en este campo es el conjunto de datos *Energy Efficiency*, introducido para estudiar la relación entre ocho variables arquitectónicas y dos variables objetivo: la carga de calefacción y la carga de enfriamiento (en la cual nos estaremos enfocando únicamente en la carga de calefacción durante este proyecto). Este conjunto contiene 768 configuraciones residenciales simuladas y ha sido utilizado ampliamente para comparar modelos lineales, árboles de decisión, redes neuronales entre otras investigaciones ((Chou & Bui, 2014; Sajjad et al., 2020)).

3) *Objetivo y Aporte del Estudio*: En este contexto, este trabajo tiene como objetivo predecir la carga de calefacción de edificios residenciales a partir de ocho características arquitectónicas empleando una implementación manual de regresión lineal. El estudio se centra en el conjunto de datos *Energy Efficiency* y desarrolla de forma explícita las etapas de exploración, transformación y ajuste del modelo mediante el algoritmo de Gradiente Descendente.

II. METODOLOGÍA

La metodología se estructuró en seis etapas secuenciales: (1) descripción y auditoría del conjunto de datos, (2) análisis exploratorio de los datos, (3) transformación y limpieza, (4) partición de los datos, (5) ingeniería de características y (6) formulación, entrenamiento y evaluación del modelo. La Figura 1.1 resume este flujo:

A. Descripción y auditoría del dataset

Se utilizó el conjunto de datos público *Energy Efficiency*, compuesto por 768 registros y 10 columnas, correspondientes a simulaciones de 12 formas base de edificaciones residenciales combinadas con distintas configuraciones de superficie acristalada, orientación y distribución de vidrio. Las variables se describen en la siguiente tabla:

TABLE I
VARIABLES DEL DATASET

Variable	Descripción	Tipo	Rol
X1	Compacidad relativa del edificio	Númerica continua	Predictora
X2	Área de superficie (m ²)	Númerica continua	Predictora
X3	Área de pared (m ²)	Númerica continua	Predictora
X4	Área de techo (m ²)	Númerica continua	Predictora
X5	Altura total (m)	Númerica continua	Predictora
X6	Orientación del edificio	Catagórica nominal	Predictora
X7	Área acristalada	Númerica continua	Predictora
X8	Distribución del área acristalada	Catagórica nominal	Predictora
X9	Carga de calefacción	Númerica continua	Objetivo
X10	Carga de enfriamiento	Númerica continua	No utilizada

Antes de cualquier transformación, se realizó una auditoría de calidad de datos con tres verificaciones: (1) conteo de valores nulos por columna, (2) conteo de filas duplicadas, (3) inspección de los valores únicos y su frecuencia en las columnas catagóricas, para confirmar que se trataba de catagorías discretas y no de variables numéricas mal etiquetadas. El dataset no presentó valores nulos ni filas duplicadas, por lo que no fue necesaria la imputación de los datos.

Esta verificación previa resulta necesaria, dado que cualquier estadístico, visualización o modelo calculado sobre los datos con valores nulos, registros duplicados o catagorías incorrectamente tipificadas queda comprometido desde su origen: un registro duplicado sobrestima artificialmente la relevancia de un patrón dentro del conjunto; un valor nulo puede interrumpir operaciones matemáticas posteriores (como el escalado de las variables o el cálculo del gradiente) y una variable catagórica no identificada, como ocurre con las variables catagóricas previamente nombradas, podría ser interpretada erróneamente por el modelo como una variable ordinal. La auditoría inicial permite, por tanto, prevenir propagación de errores no detectados a lo largo de las etapas siguientes.

TABLE II
ESTADÍSTICA DESCRIPTIVA DE LAS VARIABLES NUMÉRICAS

Variable	Media	Desv. Estándar	Mínimo	Máximo
relative_compactness	0.764	0.106	0.62	0.98
surface_area	671.71	88.09	514.50	808.50
wall_area	318.50	43.63	245.00	416.50
roof_area	176.60	45.17	110.25	220.50
overall_height	5.25	1.75	3.50	7.00
glazing_area	0.234	0.133	0.00	0.40
heating_load (Y1)	22.31	10.09	6.01	43.10
cooling_load (Y2)	24.59	9.51	10.90	48.03

Es relevante notar la heterogeneidad de escalas entre las variables predictoras: *surface_area* opera en el rango de las centenas, mientras que *relative_compactness* y *glazing_area* están acotadas entre 0 y 1. Esta disparidad entre las magnitudes es la que, más adelante, motiva la estandarización obligatoria de las variables numéricas previa al entrenamiento por el Gradiente Descendente.

B. Descripción y auditoría del dataset

El EDA se diseñó con tres objetivos: (a) caracterizar la distribución de cada variable, (b) identificar relaciones lineales entre variables predictoras y la variable objetivo, y (c) detectar posibles valores atípicos o anomalías que pudieran distorsionar el modelo.

Para la distribución univariada se generaron histogramas (20 bins) de las ocho variables numéricas para




Fig. 2. Distribución de cada variable




Fig. 3. Bloxplot entre variables

observar su forma y boxplots conjuntos para identificar valores atípicos por rango intercuartílico como se representa en la Figura 2 y 3.

Para el análisis de correlación, se calculó la matriz de correlación entre todas las variables numéricas y se visualizó como mapa de calor, con el fin de identificar que variables predictoras están mas correlacionadas con la variable objetivo, además de identificar que variables predictoras comparten información entre si.




Fig. 4. Mapa de Correlación entre variables

Para las relaciones entre las variables se examinaron mediante *scatter plots* tres relaciones específicas, elegi-

das por su relevancia arquitectónica, contra ambas variables objetivo:

1. Compacidad relativa (X1) vs carga térmica.
2. Área de superficie (X2) vs carga térmica.
3. Área de techo (X4) vs carga térmica.

Estas visualizaciones evidenciaron patrones aproximadamente lineales o monótonos entre las variables y la carga térmica, lo que constituyó la justificación para adoptar un modelo de regresión lineal como primera aproximación.

Finalmente se cuantificó la linealidad mediante regresiones simples por cada variable predictora con el fin de sustentar cuantitativamente, y no solo visualmente, la elección de un modelo lineal. Se ajustó una regresión lineal simple independiente entre cada una de las seis variables geométricas continuas (*relative_compactness*, *surface_area*, *wall_area*, *roof_area*, *overall_height*, *glazing_area*), registrando el coeficiente de determinación de cada ajuste. Este modelo permite estimar de forma individual qué proporción de la varianza de la carga térmica es explicada linealmente por cada variable predictora antes de construir el modelo.

TABLE III
COEFICIENTE DE DETERMINACIÓN (R^2) DE LAS VARIABLES PREDICTORAS

Variable	R^2 heating_load	R^2 cooling_load
relative_compactness	0.387	0.402
surface_area	0.433	0.453
wall_area	0.208	0.182
roof_area	0.743	0.744
overall_height	0.791	0.802
glazing_area	0.073	0.043

Los resultados de la Tabla III muestran que las seis variables presentan una relación lineal de magnitud apreciable y consistente con ambas cargas térmicas, sin necesidad de recurrir a transformaciones lineales. Destaca particularmente *overall_height*, que por sí sola explica cerca del 79% de la varianza tanto de *heating_load* como de *cooling_load* ($R^2 = 0.791$ y $R^2 = 0.802$ respectivamente), lo que la posiciona como la variable individualmente más informativa del conjunto. Le siguen *roof_area* ($R^2 = 0.743$ y $R^2 = 0.744$), *surface_area* ($R^2 = 0.433$ y $R^2 = 0.453$), *relative_compactness* ($R^2 = 0.387$ y $R^2 = 0.402$) y *wall_area* ($R^2 = 0.208$ y $R^2 = 0.182$), mientras que *glazing_area* presenta la asociación lineal más débil de las seis ($R^2 = 0.073$ y $R^2 = 0.043$). Es relevante notar que ninguna variable, de forma individual, explica la totalidad de la varianza de la carga térmica; esto es esperable y no invalida el enfoque lineal, sino que constituye precisamente para la construcción un modelo de regresión múltiple, en el cual el efecto conjunto y combinado de las ocho variables puede explicar una proporción considerablemente mayor de la varianza que cualquier predictora considerada de forma aislada.

Cada una de estas técnicas cumple con una función diagnóstica específica dentro del análisis exploratoria: el histograma permite evaluar si alguna variable presenta sesgo; el boxplot facilita la identificación de valores atípicos susceptibles de distorsionar el ajuste; la matriz de correlación evidencia tanto la asociación de cada variable predictora con la variable objetivo como la posible relación entre ellas mismas; y los diagramas de dispersión dirigidos permiten evaluar visualmente las relaciones más relevantes desde el punto de vista arquitectónico; y las regresiones simples de cada variable aportan una medida cuantitativa (R^2) de dicha linealidad, complementando la inspección visual con evidencia estadística. En conjunto esta etapa de análisis constituye la evidencia que respalda la elección de un modelo de regresión lineal como primera aproximación del problema, en lugar de recurrir directamente a modelos no lineales de mayor complejidad.

C. Transformación y limpieza

Sobre una copia del dataset crudo se aplicó el siguiente pipeline de transformación, ejecutando en un archivo de python independiente para separar responsabilidad (exploración vs transformación):

1. Renombrado de columnas: Se mapearon los identificadores originales a nombres descriptivos y auto-explicativos (Tabla 1), mediante un diccionario de mapeo aplicado. Esto mejora la trazabilidad del código en las etapas posteriores del modelado.
2. Retipado de variables categóricas: Las columnas *orientation* y *glazing_distribution*, que en el archivo original están codificadas como enteros (lo cual podría incluir al modelo a interpretarlas erróneamente como variables ordinales/continuas), se convirtieron explícitamente al tipo *category* de pandas, dejando explícito que son variables nominales sin orden implícito.
3. Validación final post-transformación: Se repitió la verificación de formas, nulos, duplicados y tipos de datos, como control de calidad antes de persistir el dataset limpio.
4. Persistencia: El dataset transformado exporto a *energy_efficiency_clean.csv*, desacoplando la etapa de limpieza de la etapa del modelo y garantizando reproducibilidad.

Cada una de estas transformaciones responde a un criterio específico. El renombrado de columnas incrementa la trazabilidad y auditabilidad del código en las etapas subsecuentes, dato que identificadores como X1 o Y1 carecen de significado semántico y aumenta el riesgo de confusión entre variables; al realizarse una única vez, de forma temprana y en un archivo diferente se evita repetir esta traducción conceptual en cada etapa posterior del pipeline. El retipado de *orientation* y *glazing_distribution* al tipo *category* resulta necesario porque, pese a estar codificadas como enteros en el archivo original, estas variables representan etiquetas nominales sin relación de orden ni magnitud entre sus valores; a dejarlas sin retipar expone al pipeline al riesgo de que operaciones numéricas posteriores las tratan incorrectamente como variables continuas. La repetición de la validación de integridad después de transformar constituye un control de calidad independiente del realizado en la etapa exploratoria, dado que cualquier transformación puede introducir errores anticipados. Finalmente, la persistencia del dataset transformado en un archivo CSV independiente desacopla la etapa de limpieza de la etapa de modelado, garantizando que el archivo de regresión parta siempre de un artefacto de datos único, versionado y reproducible.

D. Partición de datos (train/test)

Se utilizó una proporción 80% entrenamiento / 20% prueba, estándar en problemas de regresión. Es importante señalar que, al tratarse de un dataset de configuraciones simuladas independientes, una partición aleatoria simple es metodológicamente válida y no introduce fuga de información.

La separación entre entrenamiento y prueba constituye un requisito metodológico ineludible: entrenar y evaluar el modelo sobre las mismas observaciones impedirá distinguir si el modelo aprendió un patrón generalizable o simplemente memorizó los datos de ajuste, mientras que el conjunto de prueba, al permanecer no visto durante el entrenamiento, ofrece una estimación honesta de la capacidad de generalización del modelo. La aleatorización es igualmente necesaria dado que el dataset original se encuentra ordenado por bloques de configuración similares; una partición secuencial sin mezcla previa podría generar sesgo en la evaluación por un problema de orden de los datos y no por limitaciones reales del modelo. La fijación de la semilla aleatoria garantiza la reproducibilidad exacta del experimento entre distintas ejecuciones, condición indispensable para la verificación y depuración del trabajo. Por su parte el uso de `iloc[]` para la indexación resulta necesario porque los índices generados por `np.random.permutation(len(X))` corresponden a posiciones enteras y no a las etiquetas originales del índice del dataframe, `iloc[]` garantiza una selección correcta por posición, evitando errores que podrían presentarse si las etiquetas no coincidieran con dichas posiciones. Finalmente la función retorna cuatro estructuras independientes (`X_train`, `X_test`, `y_train`, `X_test`).

E. Ingeniería de características

Sobre `X_train` y `X_test` se aplicaron dos transformaciones, ambas implementadas manualmente ajustadas únicamente con estadísticos del conjunto de entrenamiento:

1. Codificación one-hot manual: Para cada variable categórica (*orientation* y *glazing_distribution*): Se identifican las categorías únicas presentes en X_{train} , ordenadas, y se descarta la primera. Para cada categoría restante, se crea una nueva columna binaria $c_k = 1$ [$c = k$], aplicada de forma idéntica en X_{train} y X_{test} . Finalmente la columna categórica original se elimina tras generar sus dummies, quedando de la siguiente manera.

TABLE IV
FILA DE EJEMPLO DESPUÉS DE REALIZAR ONE-HOT

Columna	Valor	Tipo
relative_compactness	1.75	Numérica (escalada)
surface_area	0.55	Numérica (escalada)
wall_area	0.03	Numérica (escalada)
roof_area	0.30	Numérica (escalada)
overall_height	-0.83	Numérica (escalada)
glazing_area	2.75	Numérica (escalada)
orientation_3	0	Dummy
orientation_4	1	Dummy
orientation_5	0	Dummy
glazing_distribution_1	0	Dummy
glazing_distribution_2	0	Dummy
glazing_distribution_3	1	Dummy
glazing_distribution_4	0	Dummy
glazing_distribution_5	0	Dummy

TABLE V
TABLA TRAS AGREGAR EL INTERCEPTO PARA CALCULAR $\hat{y} = \sum_j X_b^{(i,j)} \theta_j$

Columna	Valor	Tipo
intercepto (θ_0)	1	Bias
relative_compactness	1.75	Numérica (escalada)
surface_area	0.55	Numérica (escalada)
wall_area	0.03	Numérica (escalada)
roof_area	0.30	Numérica (escalada)
overall_height	-0.83	Numérica (escalada)
glazing_area	2.75	Numérica (escalada)
orientation_3	0	Dummy
orientation_4	1	Dummy
orientation_5	0	Dummy
glazing_distribution_1	0	Dummy
glazing_distribution_2	0	Dummy
glazing_distribution_3	1	Dummy
glazing_distribution_4	0	Dummy
glazing_distribution_5	0	Dummy

2. Estandarización manual (z-score). Para cada variable numérica continua (*relative_compactness*, *surface_area*, *wall_area*, *roof_area*, *overall_height* y *glazing_area*), se aplica una estandarización mediante *z-score*, utilizando la siguiente expresión:

$$x_j^{scaled} = \frac{x_j - \mu_j}{\sigma_j} \quad (1)$$

donde μ_j representa la media y σ_j la desviación estándar de la variable j . Estos valores se calculan exclusivamente sobre X_{train} y se almacenan en el diccionario `scaling_params`. Posteriormente, los mismos parámetros se utilizan para transformar X_{test} y cualquier nuevo dato durante la etapa de inferencia.

El uso exclusivo de X_{train} evita la fuga de información (*data leakage*), ya que X_{test} no participa en el cálculo de los parámetros utilizados para transformar los datos. De esta forma, el conjunto de prueba permanece como información no observada durante el entrenamiento.

Después de realizar la codificación one-hot y la estandarización, $X_{\text{train_scaled}}$ y $X_{\text{test_scaled}}$ contienen las seis variables numéricas estandarizadas y las variables dummy correspondientes a *orientation* y *glazing_distribution*. Estos datos quedan preparados para ser utilizados por el modelo de regresión lineal.

La codificación one-hot es necesaria porque las variables categóricas representan categorías y no valores numéricos con una relación de magnitud. Por ejemplo, si *orientation* se mantuviera como un número entero, el modelo podría interpretar incorrectamente que una categoría con un valor mayor tiene un efecto proporcionalmente mayor sobre la predicción. Las variables dummy permiten representar cada categoría de forma independiente.

Se descarta la primera categoría de cada variable categórica para evitar la *dummy variable trap*. Si se conservaran todas las categorías, las columnas dummy serían redundantes con el intercepto del modelo y producirían colinealidad perfecta.

Finalmente, la estandarización permite reducir la diferencia de escala entre las variables numéricas. Esto es especialmente importante para el Gradiente Descendente, ya que facilita que las variables produzcan gradientes de magnitudes similares y, por lo tanto, favorece una convergencia más estable durante la optimización.

1) *Optimización mediante Gradiente Descendente*: Se utilizó un modelo de Regresión Lineal Múltiple para predecir la carga de calefacción a partir de las variables obtenidas después del proceso de codificación y estandarización. La idea principal del modelo consiste en calcular la predicción como una combinación lineal de las variables predictoras. Matemáticamente, para una muestra con p características, la predicción se define como:

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_p x_p = \theta_0 + \sum_{j=1}^p \theta_j x_j \quad (2)$$

donde $\hat{y}$ representa la carga de calefacción estimada, x_j representa cada variable predictora, θ_j es el coeficiente asociado a dicha variable y θ_0 corresponde al intercepto.

Para simplificar la implementación de esta ecuación, se agregó una columna de unos al inicio de la matriz de características $\mathbf{X}$ mediante la función `add_intercept(X)`, obteniendo la matriz de diseño $\mathbf{X}_b$. Esta columna permite incorporar el intercepto θ_0 dentro de la misma operación utilizada para calcular el resto de los coeficientes. De esta manera, la predicción de una muestra i puede expresarse como:

$$\hat{y}^{(i)} = \sum_{j=0}^p X_b^{(i,j)} \theta_j \quad (3)$$

En lugar de utilizar operaciones vectorizadas o funciones de una biblioteca externa, tanto la construcción de $\mathbf{X}_b$ como el cálculo de las predicciones se implementaron mediante bucles explícitos sobre filas y columnas. La función `add_intercept(X)` construye la matriz elemento por elemento, mientras que `predict_linear(X, theta)` calcula cada predicción acumulando los productos $X_b^{(i,j)} \theta_j$. Este mismo enfoque explícito se mantiene posteriormente en el cálculo del costo y del gradiente.

2) *Optimización mediante Gradiente Descendente*: Una vez definida la función de predicción, es necesario encontrar los valores de θ que permitan obtener predicciones cercanas a los valores reales. Para ello, se utilizó una implementación manual de Gradiente Descendente, un método iterativo que ajusta los parámetros del modelo buscando minimizar una función de costo.

La función de costo utilizada fue el Error Cuadrático Medio con un factor de $\frac{1}{2}$, definida como:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(\hat{y}^{(i)} - y^{(i)} \right)^2 \quad (4)$$

donde m representa el número de muestras de entrenamiento, $\hat{y}^{(i)}$ es la predicción del modelo y $y^{(i)}$ es el valor real. Por lo tanto, cuanto menor sea $J(\theta)$, menor será el error entre las predicciones y los valores observados.

En cada iteración, Gradiente Descendente modifica los parámetros en la dirección que reduce el costo. La actualización de cada parámetro θ_j se realiza mediante:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m X_b^{(i,j)} \left(\hat{y}^{(i)} - y^{(i)} \right), \quad j = 0, 1, \dots, p \quad (5)$$

donde α representa la tasa de aprendizaje. Este valor determina el tamaño de cada actualización realizada sobre los parámetros.

La implementación se dividió en dos pasos principales dentro de cada iteración. Primero, se calcularon las predicciones y los errores para todas las muestras mediante bucles explícitos. Posteriormente, se calculó el gradiente de cada parámetro recorriendo nuevamente las muestras de entrenamiento y acumulando la contribución de cada una. Finalmente, los parámetros se actualizaron utilizando la tasa de aprendizaje seleccionada.

Los hiperparámetros utilizados fueron los siguientes:

TABLE VI
HIPERPARÁMETROS UTILIZADOS EN EL GRADIENTE DESCENDENTE

Hiperparámetro	Valor
Tasa de aprendizaje (α)	0.001
Número de iteraciones	25,000
Inicialización de θ	Vector de ceros

La tasa de aprendizaje y el número de iteraciones fueron seleccionados mediante observación exploratoria del comportamiento de la función de costo. Se probaron diferentes valores de α , observando que tasas mayores podían producir oscilaciones o divergencia, mientras que tasas menores requerían más iteraciones para alcanzar una reducción similar del costo. Finalmente, se seleccionó $\alpha = 0.001$ junto con 25,000 iteraciones, ya que esta combinación produjo una disminución estable del costo hasta su estabilización.

Durante el entrenamiento se almacenó el valor de $J(\theta)$ en cada iteración mediante `cost_history`. Esto permitió generar posteriormente una gráfica de costo contra iteración para verificar visualmente el comportamiento del algoritmo y comprobar que el costo disminuyera de manera estable en lugar de divergir u oscilar.

La estandarización realizada en la sección 2.5 es especialmente importante para este método. Gradiente Descendente utiliza los valores de las variables para calcular las actualizaciones de los parámetros, por lo que una diferencia considerable entre sus escalas puede generar gradientes de magnitudes muy diferentes. Por ejemplo, *surface_area* presenta valores mucho mayores que *relative_compactness*. Al utilizar el escalado *z-score*, las variables numéricas quedan en una escala comparable, facilitando una convergencia más estable del algoritmo.

Por otra parte, la columna de unos incorporada mediante $\mathbf{X}_b$ permite que el modelo incluya el intercepto θ_0 . Este parámetro representa el valor base de la predicción cuando las contribuciones de las demás variables se consideran iguales a cero. Sin el intercepto, el modelo estaría obligado a pasar por el origen, lo que limitaría su capacidad para representar adecuadamente la relación entre las características de los edificios y su carga de calefacción.

Finalmente, θ se inicializó como un vector de ceros. Esta elección es válida para la Regresión Lineal debido a que su función de costo es convexa y posee un único mínimo global. Por lo tanto, la inicialización en cero no impide encontrar el óptimo; simplemente proporciona un punto de partida para que Gradiente Descendente comience el proceso de optimización.

F. Métricas de evaluación

Para evaluar el desempeño del modelo, se calcularon cuatro métricas de regresión tanto sobre el conjunto de entrenamiento como sobre el conjunto de prueba. La evaluación sobre ambos conjuntos permite comparar el comportamiento del modelo durante el entrenamiento con su desempeño ante datos que no fueron utilizados para ajustar sus parámetros. Las métricas fueron implementadas mediante la función `evaluate_regression`.

1) *Error Absoluto Medio (MAE)*: El Error Absoluto Medio (*Mean Absolute Error*, MAE) mide la magnitud promedio de los errores entre las predicciones y los valores reales, sin considerar su signo. Se calcula mediante:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (6)$$

donde y_i representa el valor real, $\hat{y}_i$ la predicción del modelo y n el número de muestras evaluadas. El MAE se expresa en las mismas unidades que la variable objetivo *heating_load*, por lo que permite interpretar directamente el error promedio de una predicción.

2) *Error Cuadrático Medio (MSE)*: El Error Cuadrático Medio (*Mean Squared Error*, MSE) calcula el promedio de los errores al cuadrado:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (7)$$

Al elevar los errores al cuadrado, los errores grandes reciben un mayor peso. Por esta razón, el MSE resulta útil para identificar situaciones en las que existen predicciones considerablemente alejadas de los valores reales. A diferencia del MAE, sus unidades corresponden al cuadrado de las unidades de *heating_load*, por lo que su interpretación directa es menos intuitiva.

3) *Raíz del Error Cuadrático Medio (RMSE)*: La Raíz del Error Cuadrático Medio (*Root Mean Squared Error*, RMSE) se obtiene calculando la raíz cuadrada del MSE:

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (8)$$

El RMSE mantiene la mayor penalización sobre los errores grandes característica del MSE, pero devuelve el resultado a las mismas unidades que *heating_load*. Por ello, permite interpretar el tamaño típico del error de una manera más directa.

4) *Coficiente de Determinación (R^2)*: El Coeficiente de Determinación (R^2) permite medir qué proporción de la variabilidad observada en *heating_load* puede ser explicada por el modelo. Se calcula mediante:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (9)$$

donde $\bar{y}$ representa el promedio de los valores reales. Un valor de $R^2 = 1$ indica un ajuste perfecto, mientras que un valor cercano a 0 indica que el modelo explica poca variabilidad respecto a utilizar únicamente el promedio de la variable objetivo. En un conjunto de prueba, R^2 también puede tomar valores negativos cuando el modelo presenta un desempeño inferior al de utilizar dicho promedio como predicción.

A diferencia del MAE, MSE y RMSE, que cuantifican directamente el error de las predicciones, R^2 proporciona una medida relativa del ajuste del modelo. Por esta razón, las cuatro métricas se utilizan de manera complementaria.

5) *Evaluación visual*: Además de las métricas numéricas, se realizaron evaluaciones visuales para complementar el análisis del desempeño. Para ello, se construyeron tablas comparativas con las primeras y últimas 10 muestras de cada conjunto, mostrando el valor real, el valor predicho y el error correspondiente.

También se generaron gráficos de dispersión comparando los valores reales con las predicciones para los conjuntos de entrenamiento y prueba. En estos gráficos se incluyó una línea de referencia $y = x$, que representa el caso de una predicción perfecta. Por lo tanto, cuanto más cercanos se encuentren los puntos a esta línea, mayor será la correspondencia entre los valores reales y las predicciones del modelo.

Finalmente, la evaluación conjunta de los conjuntos de entrenamiento y prueba permite identificar posibles problemas de sobreajuste. Si el modelo presenta un desempeño considerablemente mejor en entrenamiento que en prueba, podría indicar que aprendió características específicas de los datos de entrenamiento que no se generalizan a nuevos datos. Por el contrario, resultados similares entre ambos conjuntos sugieren una capacidad de generalización más consistente. En este estudio, la comparación de las métricas obtenidas en ambos conjuntos se utilizó como evidencia para evaluar este comportamiento.

G. Prueba de integración

Para validar la aplicabilidad práctica del modelo, se implementó la función `predcir_edificio_automatico(datos_usuario)` diseñada para ejecutar de extremo a extremo el mismo *pipeline* de transformación utilizado durante el entrenamiento. La función recibe un diccionario que contiene las ocho características de un edificio hipotético y realiza secuencialmente las siguientes operaciones:

1. Recepción de los datos del nuevo edificio en su formato original.
2. Codificación *one-hot* de las variables categóricas, utilizando únicamente las categorías identificadas durante el entrenamiento y generando las correspondientes variables dummy.
3. Estandarización de las variables numéricas mediante los parámetros μ_j y σ_j almacenados en `scaling_params` durante el entrenamiento.
4. Reindexación de las columnas para garantizar que la estructura y el orden de las características coincidan exactamente con los utilizados por `X_train_scaled`. Las variables dummy que no correspondan al edificio evaluado se asignan con valor cero.
5. Incorporación del intercepto mediante la construcción de $\mathbf{X}_b$ y cálculo de la predicción utilizando los parámetros θ aprendidos durante el entrenamiento. La predicción se obtiene mediante el mismo procedimiento de recorrido explícito por filas y columnas utilizado por la función `predict_linear`.

Esta prueba resulta metodológicamente relevante porque verifica que el proceso de *feature engineering* sea reutilizable y consistente entre las etapas de entrenamiento e inferencia. En particular, permite comprobar que un nuevo edificio puede procesarse a partir de sus características originales sin necesidad de repetir el proceso de ajuste de las transformaciones ni modificar la estructura utilizada por el modelo.

La prueba de integración complementa las métricas MAE, MSE, RMSE y R^2 obtenidas sobre el conjunto de prueba. Mientras que estas métricas cuantifican el desempeño agregado del modelo sobre observaciones previamente transformadas, la prueba de inferencia verifica el funcionamiento del *pipeline* completo ante una observación individual presentada en su formato original, simulando un escenario de uso más cercano a una aplicación real.

Como resultado, la prueba demuestra que el modelo no únicamente alcanza un desempeño cuantitativo satisfactorio sobre el conjunto de prueba, sino que también puede recibir una observación nueva en formato de entrada, aplicar de manera consistente las mismas transformaciones utilizadas durante el entrenamiento y generar una predicción de *heating_load* sin intervención manual en las etapas intermedias.




Fig. 5. Evolución de la función de costo $J(\theta)$ durante las 25,000 iteraciones del Gradiente Descendente.

III. RESULTADOS

En esta sección se presentan los resultados obtenidos durante el entrenamiento, evaluación e inferencia del modelo de regresión lineal múltiple implementado mediante Gradiente Descendente. El análisis se divide en cuatro aspectos: la convergencia del algoritmo de optimización, el desempeño global del modelo, el comportamiento de las predicciones a nivel individual y, finalmente, una prueba de integración sobre un edificio hipotético no incluido en el conjunto de datos original.

A. Convergencia del Gradiente Descendente

La Figura 1 muestra la evolución de la función de costo $J(\theta)$ a lo largo de las 25,000 iteraciones utilizadas durante el entrenamiento del modelo. La función de costo corresponde al Error Cuadrático Medio con un factor de $\frac{1}{2}$, definida previamente en la sección de formulación del modelo.

El costo inicial fue de 294.58, mientras que al finalizar el entrenamiento se obtuvo un valor de 4.13. Esto representa una reducción aproximada del 98.6% respecto al costo inicial, lo que evidencia una disminución considerable del error durante el proceso de optimización.

La curva de convergencia presenta tres comportamientos principales. En primer lugar, se observa una caída pronunciada durante las primeras aproximadamente 1,000 iteraciones, periodo en el cual las actualizaciones de los parámetros θ son relativamente grandes debido a que el modelo se encuentra alejado de la región óptima. Posteriormente, entre aproximadamente las iteraciones 1,000 y 5,000, la reducción del costo se vuelve progresivamente más suave. Finalmente, a partir de aproximadamente la iteración 5,000, la curva presenta una estabilización, indicando que las actualizaciones de los parámetros se vuelven pequeñas y el algoritmo se aproxima a una región de mínimo.

Este comportamiento indica que la tasa de aprendizaje seleccionada, $\alpha = 0.001$, permitió realizar actualizaciones suficientemente grandes para reducir el costo sin producir divergencia u oscilaciones. Asimismo, la estandarización de las variables numéricas realizada previamente contribuyó a mantener las magnitudes de los gradientes en escalas comparables, facilitando la convergencia del algoritmo.

Una vez finalizado el proceso de optimización, los parámetros aprendidos por el modelo fueron los siguientes:

TABLE VII
VECTOR θ APRENDIDO POR EL GRADIENTE DESCENDENTE

Parámetro	Variable	Valor
θ_0	Intercepto	17.9642
θ_1	relative_compactness	-2.0629
θ_2	surface_area	-1.1620
θ_3	wall_area	1.8186
θ_4	roof_area	-2.0153
θ_5	overall_height	7.1220
θ_6	glazing_area	2.3642
θ_7	orientation_3	1.0862
θ_8	orientation_4	1.1253
θ_9	orientation_5	0.9590
θ_{10}	glazing_distribution_1	3.5715
θ_{11}	glazing_distribution_2	3.8090
θ_{12}	glazing_distribution_3	3.6000
θ_{13}	glazing_distribution_4	3.2214
θ_{14}	glazing_distribution_5	3.5983

El intercepto $\theta_0 = 17.9642$ representa la predicción base del modelo cuando las variables numéricas estandarizadas toman el valor cero y las variables categóricas se encuentran en sus categorías de referencia. En el caso de las variables numéricas estandarizadas, un valor de cero corresponde a la media calculada sobre el conjunto de entrenamiento.

Entre las variables numéricas, el coeficiente de mayor magnitud absoluta corresponde a *overall_height*, con $\theta_5 = 7.1220$. Debido a que las variables numéricas fueron estandarizadas, la magnitud de estos coeficientes permite comparar el efecto asociado a un incremento de una desviación estándar en cada variable, manteniendo constantes las demás variables del modelo.

Por otra parte, *relative_compactness* presentó un coeficiente de $\theta_1 = -2.0629$, mientras que *roof_area* presentó $\theta_4 = -2.0153$. Los signos negativos indican que, manteniendo constantes las demás variables, un incremento en estas variables se asocia con una disminución de la carga de calefacción según el modelo ajustado.

Las variables correspondientes a *glazing_distribution* presentaron coeficientes positivos y relativamente similares, con valores comprendidos aproximadamente entre 3.22 y 3.81. Estos coeficientes representan el efecto de cada categoría respecto a la categoría de referencia que fue omitida durante la codificación one-hot.

Es importante señalar que la magnitud de un coeficiente no debe interpretarse de manera aislada como una medida definitiva de importancia causal. Los coeficientes representan asociaciones condicionadas al resto de las variables incluidas en el modelo y deben interpretarse conjuntamente con las características del conjunto de datos y las transformaciones realizadas.

B. Desempeño del modelo

El desempeño del modelo se evaluó tanto sobre el conjunto de entrenamiento como sobre el conjunto de prueba. Esta comparación permite determinar no solo qué tan bien se ajustó el modelo a los datos utilizados durante el aprendizaje, sino también qué tan bien generaliza hacia observaciones que permanecieron fuera del proceso de entrenamiento.

Los resultados obtenidos se presentan en la Tabla VIII.




Fig. 6. Comparación entre los valores reales y predichos para los conjuntos de entrenamiento y prueba.

TABLE VIII
MÉTRICAS DE EVALUACIÓN DEL MODELO (GRADIENTE DESCENDENTE)

Métrica	Entrenamiento	Prueba
MAE	2.0753	2.1814
MSE	8.2537	9.1251
RMSE	2.8729	3.0208
R^2	0.9182	0.9124

El conjunto de prueba obtuvo un MAE de 2.1814, lo que significa que, en promedio, las predicciones del modelo se encontraron aproximadamente 2.18 unidades de *heating_load* respecto a los valores reales. Considerando que la variable objetivo presenta un rango entre 6.01 y 43.10 unidades, el error obtenido resulta relativamente pequeño respecto a la amplitud total observada en la variable.

El valor de $R^2 = 0.9124$ obtenido sobre el conjunto de prueba indica que el modelo explica aproximadamente el 91.24% de la variabilidad observada en la carga de calefacción dentro de dicho conjunto. Este resultado representa un ajuste elevado para el modelo lineal implementado.

La diferencia entre el desempeño de entrenamiento y prueba también resulta reducida. El MAE aumenta de 2.0753 a 2.1814, mientras que R^2 disminuye de 0.9182 a 0.9124. Esta diferencia relativamente pequeña entre ambos conjuntos no proporciona evidencia de un sobreajuste considerable, ya que el modelo mantiene un desempeño similar al enfrentarse a datos que no fueron utilizados durante el entrenamiento.

La Figura 2 presenta la comparación entre los valores reales y las predicciones obtenidas por el modelo para los conjuntos de entrenamiento y prueba.

En ambos conjuntos, los puntos se concentran alrededor de la diagonal $y = x$, lo que indica una correspondencia elevada entre los valores reales y las predicciones. La proximidad de los puntos respecto a esta línea también es consistente con los valores reducidos de MAE y RMSE obtenidos durante la evaluación.

No obstante, se observa una dispersión ligeramente mayor en las observaciones con valores elevados de *heating_load*, particularmente por encima de aproximadamente 35 unidades. Algunos puntos presentan una separación considerable respecto a la línea de predicción perfecta. Este comportamiento sugiere que, aunque el modelo captura adecuadamente la tendencia general de la variable objetivo, existen patrones o interacciones que no son completamente representados mediante una combinación lineal de las variables predictoras.

C. Análisis muestra a muestra

Además de las métricas agregadas, se analizaron predicciones individuales del conjunto de prueba para observar directamente el comportamiento del modelo sobre casos específicos. Las Tablas IX y X muestran las primeras y últimas diez observaciones del conjunto de prueba, respectivamente.

TABLE IX
PRIMERAS 10 MUESTRAS DEL CONJUNTO DE PRUEBA (REAL VS. PREDICHO)

Real (y)	Predicho ($\hat{y}$)	Error ($y - \hat{y}$)
16.47	18.59	-2.12
13.17	13.73	-0.56
32.82	31.52	1.30
41.32	34.78	6.54
16.69	15.56	1.13
23.80	27.07	-3.27
24.31	27.52	-3.21
28.67	29.08	-0.41
19.52	17.47	2.05
28.07	27.62	0.45

TABLE X
ÚLTIMAS 10 MUESTRAS DEL CONJUNTO DE PRUEBA (REAL VS. PREDICHO)

Real (y)	Predicho ($\hat{y}$)	Error ($y - \hat{y}$)
31.53	31.39	0.14
35.73	33.62	2.11
11.42	12.41	-0.99
10.07	8.18	1.89
28.09	28.56	-0.47
35.01	34.00	1.01
38.98	32.55	6.43
36.66	34.01	2.65
29.34	28.81	0.53
29.54	28.58	0.96

La mayoría de los errores individuales observados en estas muestras se encuentran dentro de un intervalo aproximado de ± 3 unidades, lo cual es consistente con el MAE global de 2.18 obtenido sobre el conjunto de prueba. Sin embargo, también se identifican errores considerablemente mayores en algunas observaciones.

El mayor error mostrado en las tablas corresponde a 6.54 unidades, asociado a una observación cuyo valor real de *heating_load* es 41.32, mientras que el modelo predijo 34.78. De manera similar, se observa un error de 6.43 unidades para una observación con un valor real de 38.98 y una predicción de 32.55.

Ambos casos se encuentran en la zona de valores elevados de carga de calefacción y son consistentes con la mayor dispersión observada en la Figura 2. Esto sugiere que los errores más importantes del modelo se concentran principalmente en determinadas observaciones de alta demanda térmica.

El análisis muestra a muestra complementa las métricas globales, ya que permite identificar comportamientos particulares que no pueden observarse directamente mediante un único valor agregado como el MAE o el R^2 .

D. Prueba de integración

Como validación adicional del funcionamiento del sistema completo, se ejecutó la función `predecir_edificio_automatico` sobre un edificio hipotético no incluido en el conjunto de datos original. Esta prueba tuvo como objetivo verificar que el modelo pudiera recibir características en su formato original y realizar automáticamente las transformaciones necesarias antes de generar una predicción.

Las características utilizadas para el edificio hipotético fueron:

TABLE XI
CARACTERÍSTICAS DEL EDIFICIO UTILIZADO EN LA PRUEBA DE INTEGRACIÓN

Variable	Valor
relative_compactness	0.82
surface_area	612.5 m ²
wall_area	318.5 m ²
roof_area	147.0 m ²
overall_height	7 m
glazing_area	0.10
orientation	2
glazing_distribution	2

A partir de estos datos, la función ejecutó el pipeline completo de inferencia. En primer lugar, se realizó la codificación one-hot de las variables categóricas utilizando las categorías identificadas durante el entrenamiento. Posteriormente, las variables numéricas fueron estandarizadas utilizando exclusivamente los parámetros μ_j y σ_j almacenados previamente en `scaling_params`. Finalmente, las columnas resultantes fueron reindexadas para coincidir exactamente con la estructura utilizada durante el entrenamiento y se calculó la predicción mediante los parámetros θ aprendidos por el Gradiente Descendente.

El resultado obtenido fue:

$$\hat{y} \approx 23.85 \quad (10)$$

Por lo tanto, para las características proporcionadas, el modelo estima una carga de calefacción aproximada de 23.85 unidades.

Este resultado demuestra que el modelo no requiere que el usuario proporcione manualmente los datos ya codificados y estandarizados. En su lugar, la función de inferencia reproduce automáticamente las transformaciones realizadas durante el entrenamiento, manteniendo la misma estructura de características utilizada por el modelo.

El MAE obtenido sobre el conjunto de prueba, 2.1814, puede utilizarse como referencia del error promedio esperado del modelo. Sin embargo, este valor no constituye por sí mismo un intervalo de predicción ni implica que la predicción individual sea necesariamente de 23.85 ± 2.18 . Por ello, el resultado debe interpretarse como una estimación puntual cuyo error promedio, evaluado sobre el conjunto de prueba, fue de aproximadamente 2.18 unidades.

E. Implementación con Framework: Random Forest

1) *Justificación del segundo modelo:* A partir de los resultados obtenidos con el modelo de regresión lineal presentado en las secciones anteriores, se identificó que la relación entre las variables arquitectónicas y `heating_load` puede aproximarse de manera razonable mediante una combinación lineal, pero que dicha aproximación presenta limitaciones en determinadas regiones del conjunto de datos. En particular, el análisis de los valores predichos y de los residuos mostró que los errores más importantes tienden a concentrarse en observaciones con valores elevados de `heating_load`, especialmente por encima de aproximadamente 35 unidades.

Esta situación resulta relevante debido a que el objetivo del modelo no consiste únicamente en obtener una aproximación general de la carga térmica, sino en capturar de la manera más precisa posible la relación existente entre las características geométricas de un edificio y su demanda energética. Una regresión lineal supone que el efecto de cada variable predictora puede representarse mediante un coeficiente constante y que los efectos individuales se combinan de forma aditiva. En términos generales, el modelo puede expresarse como:

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_p x_p \quad (11)$$

Esta estructura permite interpretar fácilmente el efecto marginal de cada variable, pero también limita

la capacidad del modelo para representar relaciones no lineales o interacciones entre variables. Por ejemplo, el efecto de `relative_compactness` sobre la carga térmica podría depender simultáneamente de `surface_area`, `roof_area` u `overall_height`. Una regresión lineal convencional no incorpora este tipo de interacción a menos que dichas relaciones sean definidas explícitamente mediante términos adicionales.

Para evaluar si una estructura más flexible podía representar mejor la relación entre las variables predictoras y `heating_load`, se implementó un segundo modelo mediante el framework `scikit-learn`: un *Random Forest Regressor*. La selección de este algoritmo se debe principalmente a su capacidad para modelar relaciones no lineales e interacciones entre variables sin requerir que estas sean especificadas manualmente durante la etapa de ingeniería de características.

Además, Random Forest resulta apropiado para este conjunto de datos porque permite trabajar simultáneamente con variables numéricas y categóricas después de su correspondiente transformación, no requiere estandarización de las variables numéricas y proporciona mecanismos para analizar la importancia relativa de las variables utilizadas durante el proceso de predicción.

De esta manera, la implementación del segundo modelo permite establecer una comparación entre dos enfoques con características diferentes: por un lado, la regresión lineal, que proporciona un modelo sencillo, interpretable y con una estructura matemática explícita; por otro, Random Forest, que sacrifica parte de dicha interpretabilidad a cambio de una mayor capacidad para representar patrones complejos en los datos.

2) *Fundamento teórico de Random Forest*: Random Forest es un algoritmo propuesto por Breiman (2001, (Breiman, 2001)) que combina múltiples árboles de decisión para construir un predictor más robusto que cualquiera de los árboles individuales que lo componen.

Un árbol de decisión realiza predicciones mediante una secuencia de divisiones de los datos. En cada nodo, el algoritmo selecciona una variable y un punto de corte que permiten dividir las observaciones en grupos progresivamente más homogéneos respecto a la variable objetivo. Aunque este procedimiento permite representar relaciones no lineales, un árbol individual puede alcanzar una elevada complejidad y adaptarse excesivamente a las observaciones utilizadas durante su entrenamiento, produciendo un modelo con alta varianza.

Random Forest reduce este problema mediante la construcción de múltiples árboles y la combinación de sus predicciones. La diversidad entre los árboles se introduce principalmente mediante dos mecanismos:

1. **Cada árbol aprende de una muestra distinta.** En lugar de entrenar todos los árboles con exactamente las mismas 768 observaciones, cada árbol se entrena con una muestra aleatoria tomada con reemplazo a partir del conjunto de entrenamiento original. Esto significa que algunas observaciones pueden repetirse en la muestra de un árbol y no aparecer en la de otro. Como consecuencia, cada árbol aprende a partir de una versión ligeramente distinta de los datos, lo que evita que todos memoricen exactamente el mismo patrón y reduce el riesgo de que el bosque completo se sobreajuste al conjunto de entrenamiento.
2. **Cada división considera solo algunas variables.** Al construir cada árbol, en cada punto donde se decide cómo dividir las observaciones, el algoritmo no evalúa las ocho variables disponibles, sino únicamente un subconjunto aleatorio de ellas. Esto evita que todos los árboles del bosque tiendan a usar siempre las variables más influyentes (como `overall_height` o `roof_area`) en sus primeras divisiones, y obliga a que distintos árboles exploren distintas combinaciones de variables.

Ambos mecanismos combinados generan un conjunto de árboles suficientemente distintos entre sí, de modo que los errores particulares de cada uno tienden a compensarse al promediar sus predicciones. La combinación de estos mecanismos permite obtener un conjunto de árboles suficientemente diversos para que sus errores individuales tiendan a compensarse al combinar sus predicciones. En un problema de regresión, como el utilizado para predecir `heating_load`, la predicción final se obtiene mediante el promedio de las predicciones producidas por los T árboles del bosque:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x) \quad (12)$$

donde $f_t(x)$ representa la predicción realizada por el árbol t para una observación x , y T corresponde al número total de árboles del bosque.

El promedio de múltiples árboles permite reducir la varianza del modelo respecto a un árbol individual. Intuitivamente, aunque algunos árboles pueden producir predicciones ligeramente diferentes debido a las muestras bootstrap y a la selección aleatoria de variables, la combinación de sus resultados produce una estimación más estable.

Una característica importante de Random Forest es que no necesita asumir una forma funcional específica para la relación entre las variables de entrada y la variable objetivo. Mientras que la regresión lineal busca estimar una función lineal de la forma presentada anteriormente, Random Forest construye una aproximación mediante múltiples regiones de decisión. Por esta razón, puede capturar automáticamente comportamientos como cambios de pendiente, relaciones no lineales y determinadas interacciones entre variables.

Esta característica resulta particularmente relevante para el conjunto de datos *Energy Efficiency*, debido a que las variables arquitectónicas no necesariamente afectan la carga térmica de manera independiente. La combinación de características como el área superficial, el área del techo, la altura del edificio y la compacidad puede generar diferentes comportamientos energéticos dependiendo de la configuración específica del edificio.

Otra diferencia importante respecto a la regresión lineal es que Random Forest no requiere estandarizar las variables numéricas. Debido a que los árboles de decisión realizan divisiones basadas en el orden relativo y en umbrales de corte sobre los valores de cada variable, la magnitud de la escala no afecta la capacidad del modelo para estructurar las particiones. En consecuencia, variables como *surface_area* y *overall_height* pueden utilizarse directamente en sus escalas originales sin alterar el desempeño del algoritmo.

Sin embargo, esta flexibilidad tiene como principal desventaja una menor interpretabilidad. Mientras que en la regresión lineal cada coeficiente puede interpretarse como el cambio esperado en la variable objetivo asociado con un incremento unitario de una variable, manteniendo las demás constantes, Random Forest no produce un único conjunto de coeficientes con una interpretación equivalente. El modelo está formado por múltiples árboles y numerosas reglas de decisión, por lo que su relación completa entre las variables de entrada y la predicción resulta considerablemente más compleja de expresar.

Random Forest




Fig. 7. Esquema conceptual del funcionamiento de Random Forest. Cada árbol se entrena utilizando una muestra bootstrap del conjunto de entrenamiento y un subconjunto aleatorio de variables durante las divisiones. La predicción final para un problema de regresión corresponde al promedio de las predicciones individuales de todos los árboles.

3) *Implementación mediante scikit-learn*: A diferencia de la implementación del modelo lineal, en la cual algunas de las operaciones fueron realizadas directamente mediante NumPy para mostrar el funcionamiento matemático del algoritmo, el segundo modelo se implementó utilizando las herramientas proporcionadas por el framework *scikit-learn* ((Pedregosa et al., 2011)).

El objetivo de utilizar el framework no fue únicamente simplificar la implementación del algoritmo, sino construir un flujo de procesamiento reproducible en el que las transformaciones de los datos y el modelo de aprendizaje quedaran integrados en una misma estructura. Para ello se utilizaron principalmente las clases `ColumnTransformer`, `OneHotEncoder`, `RandomForestRegressor` y `Pipeline`.

Esta estructura permite separar claramente tres etapas del proceso: la preparación de las variables, la transformación de las variables categóricas y el entrenamiento del modelo. Además, al utilizar un `Pipeline`, estas operaciones quedan encadenadas y se ejecutan automáticamente en el orden correspondiente cuando se llama a los métodos `fit()` y `predict()`.

4) *Pipeline de preprocesamiento*: El conjunto de datos contiene tanto variables numéricas como variables categóricas. Las variables numéricas corresponden a *relative_compactness*, *surface_area*, *wall_area*, *roof_area*, *overall_height* y *glazing_area*, mientras que *orientation* y *glazing_distribution* son variables categóricas.

Debido a que un estimador de aprendizaje automático requiere que sus entradas estén representadas numéricamente, las variables categóricas se transformaron mediante `OneHotEncoder`. Esta transformación genera una variable binaria para cada categoría existente. Por ejemplo, las diferentes orientaciones presentes en el conjunto de datos se representan mediante columnas independientes que toman valores de 0 o 1 dependiendo de la categoría correspondiente a cada observación.

El procesamiento se implementó mediante un `ColumnTransformer`, que permite aplicar transformaciones diferentes a grupos específicos de columnas. La configuración utilizada puede resumirse de la siguiente manera:

1. Las variables *orientation* y *glazing_distribution* se transformaron mediante `OneHotEncoder`.
2. Se utilizó `handle_unknown="ignore"` para evitar errores durante la predicción si apareciera una categoría que no hubiera sido observada durante el entrenamiento.
3. Las variables numéricas se mantuvieron en su escala original mediante `remainder="passthrough"`, ya que `Random Forest` no requiere estandarización.
4. Finalmente, el resultado del preprocesamiento se conectó directamente con el estimador `RandomForestRegressor` mediante un objeto `Pipeline`.

La utilización de `Pipeline` también contribuye a prevenir problemas de *data leakage*. Las transformaciones necesarias para preparar los datos se ajustan únicamente utilizando el conjunto de entrenamiento durante la llamada a `fit()`. Posteriormente, las mismas transformaciones aprendidas se aplican al conjunto de prueba sin volver a estimar sus parámetros a partir de este conjunto.

Este procedimiento garantiza que la información contenida en los datos de prueba no sea utilizada indirectamente durante el entrenamiento del modelo. Por lo tanto, las métricas obtenidas sobre el conjunto de prueba proporcionan una evaluación más adecuada de la capacidad de generalización del modelo.

5) *División del conjunto de datos*: Para mantener condiciones comparables con el modelo de regresión lineal, se utilizó una proporción de aproximadamente 80% de los datos para entrenamiento y 20% para prueba.

En esta implementación, la división se realizó mediante la función `train_test_split` proporcionada por *scikit-learn*. Se estableció `random_state=42` con el propósito de garantizar que la partición pudiera reproducirse en ejecuciones posteriores.

Debido a que el conjunto de datos contiene 768 observaciones, la división realizada mediante `train_test_split` produjo 614 observaciones para entrenamiento y 154 para prueba. La implementación manual utilizada anteriormente produjo una partición de 615 y 153 observaciones, respectivamente. Esta diferencia de un registro se debe al procedimiento específico de redondeo y partición utilizado por cada implementación y representa una diferencia mínima en relación con el tamaño total del conjunto de datos.

Por esta razón, los resultados pueden compararse como una referencia general del comportamiento de ambos modelos, aunque strictly hablando no fueron obtenidos sobre exactamente las mismas observaciones de entrenamiento y prueba.

6) *Configuración de los hiperparámetros*: El modelo Random Forest se configuró utilizando los hiperparámetros mostrados en la Tabla XII.

TABLE XII
HIPERPARÁMETROS UTILIZADOS EN RANDOM FOREST

Hiperparámetro	Valor	Descripción
n_estimators	300	Número de árboles utilizados para construir el bosque.
max_depth	15	Profundidad máxima permitida para cada árbol.
random_state	42	Semilla utilizada para garantizar reproducibilidad.
n_jobs	-1	Utiliza todos los núcleos disponibles para paralelizar el entrenamiento.

El parámetro `n_estimators=300` determina que el bosque estará compuesto por 300 árboles de decisión. Utilizar un número elevado de árboles permite obtener un promedio más estable de las predicciones individuales. En términos generales, incrementar el número de árboles tiende a reducir la variabilidad del resultado, aunque después de cierto punto la mejora en desempeño se vuelve cada vez menor mientras aumenta el costo computacional.

Por otro lado, `max_depth=15` establece una profundidad máxima para los árboles. Este parámetro limita indirectamente la complejidad de cada estimador individual, evitando que los árboles crezcan indefinidamente y memoricen detalles excesivamente específicos del conjunto de entrenamiento.

El parámetro `random_state=42` se utilizó para garantizar la reproducibilidad del experimento. Random Forest incorpora diferentes procesos aleatorios durante la construcción del bosque, por lo que fijar una semilla permite obtener los mismos resultados al volver a ejecutar el código bajo las mismas condiciones.

Finalmente, `n_jobs=-1` permite utilizar todos los núcleos disponibles del procesador durante las operaciones que pueden paralelizarse. Debido a que cada árbol del bosque puede entrenarse de manera independiente, este procedimiento permite reducir el tiempo de ejecución sin modificar conceptualmente el modelo.

F. Resultados del modelo Random Forest

Una vez construido el Pipeline, el modelo se entrenó exclusivamente con el conjunto de entrenamiento y posteriormente se utilizaron ambos conjuntos para obtener las predicciones necesarias para evaluar su desempeño.

Las métricas obtenidas se presentan en la Tabla XIII.

TABLE XIII
MÉTRICAS DE EVALUACIÓN DEL MODELO RANDOM FOREST

Métrica	Entrenamiento	Prueba
MAE	0.1209	0.3670
MSE	0.0347	0.2835
RMSE	0.1864	0.5324
R^2	0.9997	0.9973

Los resultados muestran un desempeño considerablemente elevado. Sobre el conjunto de prueba, Random Forest obtuvo un MAE de 0.3670, lo que significa que, en promedio, la diferencia absoluta entre la carga térmica real y la predicha fue inferior a media unidad. El RMSE fue de 0.5324, indicando que incluso al penalizar de manera más fuerte los errores de mayor magnitud, el error permaneció relativamente reducido.

El valor de $R^2 = 0.9973$ indica que aproximadamente el 99.73% de la variabilidad observada en *heating_load* es explicada por las predicciones del modelo sobre el conjunto de prueba. El R^2 restante, correspondiente a

aproximadamente 0.27% de variabilidad no explicada, es considerablemente menor que el observado en el modelo de regresión lineal.

También resulta importante analizar la diferencia entre el desempeño obtenido durante el entrenamiento y el obtenido sobre datos no utilizados durante el ajuste. En entrenamiento, el modelo obtuvo un $R^2 = 0.9997$ y un MAE de 0.1209, mientras que en prueba alcanzó un $R^2 = 0.9973$ y un MAE de 0.3670. Aunque existe una degradación del desempeño al pasar de entrenamiento a prueba, esta diferencia es relativamente pequeña considerando la flexibilidad del modelo.

En particular, la diferencia de R^2 es de apenas 0.0024. Esto indica que el modelo mantiene una capacidad predictiva muy elevada cuando se enfrenta a observaciones que no fueron utilizadas para construir los árboles. Por lo tanto, los resultados no muestran evidencia de un sobreajuste severo bajo la configuración utilizada.




Fig. 8. Valores reales frente a valores predichos por Random Forest para los conjuntos de entrenamiento y prueba.

La Figura 8 permite observar visualmente la relación entre los valores reales de *heating_load* y las predicciones generadas por el modelo. La línea diagonal $y = x$ representa el escenario ideal, en el cual el valor predicho coincide exactamente con el valor real.

Los puntos correspondientes a Random Forest se encuentran concentrados alrededor de esta línea a lo largo de prácticamente todo el rango de la variable objetivo. Esta concentración es especialmente relevante al compararla con el comportamiento observado en la regresión lineal, donde se identificó una mayor dispersión en la región de valores elevados de *heating_load*.

Por lo tanto, la representación gráfica respalda los resultados obtenidos mediante las métricas numéricas: el modelo es capaz de aproximar con mayor precisión tanto las observaciones centrales como aquellas asociadas con valores elevados de carga térmica.




Fig. 9. Distribución de los residuos obtenidos mediante Random Forest para los conjuntos de entrenamiento y prueba.

La distribución de los residuos presentada en la Figura 9 proporciona una segunda perspectiva sobre el desempeño del modelo. Un residuo cercano a cero indica que la predicción se encuentra próxima al valor observado, mientras que valores alejados de cero representan errores de mayor magnitud.

En este caso, la concentración de los residuos alrededor de cero es consistente con el bajo MAE y RMSE obtenidos. Además, la ausencia de una dispersión sistemática claramente marcada permite considerar que el modelo no presenta un patrón de error evidente comparable con el observado en el modelo lineal.

1) *Prueba de integración:* Como prueba adicional del funcionamiento del modelo, se utilizó el edificio hipotético definido previamente en la Tabla XI. La observación fue introducida al mismo Pipeline utilizado durante el entrenamiento, de manera que las transformaciones necesarias para las variables categóricas fueran aplicadas automáticamente antes de generar la predicción.

Para este edificio, Random Forest produjo una predicción de aproximadamente:

$$\hat{y}_{RF} \approx 23.57 \quad (13)$$

Este resultado puede compararse con la predicción de aproximadamente 23.85 obtenida mediante el modelo de regresión lineal para la misma observación. La diferencia entre ambos modelos es de aproximadamente 0.28 unidades.

La similitud entre ambas predicciones resulta relevante porque muestra que, aunque los modelos utilizan estructuras matemáticas considerablemente diferentes, pueden converger hacia valores similares para determinadas observaciones. En este caso particular, el edificio hipotético se encuentra en una región del espacio de características donde ambos modelos producen estimaciones próximas.

Sin embargo, esta coincidencia no implica que ambos modelos tengan un comportamiento equivalente para todo el conjunto de datos. Los resultados globales muestran que Random Forest presenta una ventaja considerable en términos de error predictivo, por lo que la similitud observada debe interpretarse únicamente como el comportamiento de ambos modelos para esta observación específica.

G. Comparación entre Regresión Lineal y Random Forest

Para evaluar de manera conjunta los dos enfoques implementados, se compararon las métricas obtenidas sobre los respectivos conjuntos de prueba. Los resultados se presentan en la Tabla XIV.

TABLE XIV
COMPARACIÓN DE MÉTRICAS OBTENIDAS SOBRE EL CONJUNTO DE PRUEBA

Métrica	Regresión Lineal (GD)	Random Forest
MAE	2.1814	0.3670
MSE	9.1251	0.2835
RMSE	3.0208	0.5324
R^2	0.9124	0.9973

La comparación muestra una diferencia clara entre ambos modelos. Random Forest obtuvo mejores resultados en las cuatro métricas evaluadas. El MAE disminuyó de 2.1814 en la regresión lineal a 0.3670 en Random Forest, lo que representa una reducción aproximada del 83.2% en el error absoluto promedio.

De manera similar, el RMSE pasó de 3.0208 a 0.5324, equivalente a una reducción aproximada del 82.4%. Esta reducción es particularmente importante porque el RMSE asigna un mayor peso a los errores grandes y, por lo tanto, indica que Random Forest no solamente mejora el error promedio, sino que también reduce considerablemente la presencia de errores de gran magnitud.

En cuanto al coeficiente de determinación, la regresión lineal obtuvo un $R^2 = 0.9124$, mientras que Random Forest alcanzó $R^2 = 0.9973$. Esto implica que la proporción de variabilidad no explicada, calculada como $1 - R^2$, disminuyó de 0.0876 a 0.0027.

La diferencia de desempeño puede explicarse por la estructura funcional de ambos modelos. La regresión lineal supone que cada variable contribuye de manera aditiva y mediante un efecto constante. Random For-

est, en cambio, divide progresivamente el espacio de características mediante reglas de decisión, permitiendo representar relaciones no lineales e interacciones sin necesidad de definirlas explícitamente.

Esta capacidad parece ser especialmente relevante para el conjunto *Energy Efficiency*. Las variables arquitectónicas utilizadas para predecir *heating_load* no necesariamente producen efectos independientes. Por ejemplo, una determinada superficie de techo puede tener un efecto diferente dependiendo de la altura o de la compacidad relativa del edificio. Random Forest puede aproximar este tipo de comportamiento mediante diferentes divisiones en sus árboles, mientras que la regresión lineal requeriría incorporar manualmente términos de interacción o transformaciones no lineales.




Fig. 10. Comparación de las métricas de desempeño de Random Forest entre los conjuntos de entrenamiento y prueba.

No obstante, la superioridad predictiva de Random Forest implica una contrapartida en términos de interpretabilidad. En el modelo lineal, los coeficientes obtenidos mediante Gradiente Descendente permiten cuantificar directamente el efecto asociado con cada variable predictora, manteniendo constantes las demás variables. Esto facilita la interpretación del modelo y permite relacionar los resultados matemáticos con características concretas del edificio.

Random Forest no proporciona una ecuación equivalente que pueda interpretarse mediante un conjunto reducido de coeficientes. La predicción final depende de las decisiones realizadas por múltiples árboles y de la combinación de sus resultados. Si bien el algoritmo permite obtener medidas de importancia de variables, estas indican principalmente qué variables contribuyen al proceso predictivo y no proporcionan por sí mismas una interpretación directa de la dirección o magnitud del efecto.

También existe una diferencia en términos de complejidad computacional. La regresión lineal puede entrenarse mediante un procedimiento relativamente sencillo y con un costo computacional reducido, mientras que Random Forest requiere construir 300 árboles de decisión. Sin embargo, esta diferencia no representa una limitación significativa para el conjunto de datos utilizado, debido a que contiene únicamente 768 observaciones. Por lo tanto, el costo adicional de entrenamiento permanece bajo y resulta aceptable frente a la mejora obtenida en precisión.

En consecuencia, los resultados muestran que los dos modelos cumplen objetivos diferentes dentro del análisis. La regresión lineal proporciona una representación sencilla y directamente interpretable de la relación entre las características arquitectónicas y la carga térmica. Random Forest, por su parte, ofrece una representación considerablemente más flexible y obtiene un desempeño predictivo superior sobre los datos evaluados.

Para el objetivo específico de predecir *heating_load*, Random Forest constituye el modelo con mejor desempeño entre los dos enfoques implementados. Sin embargo, la regresión lineal conserva un valor importante desde una perspectiva analítica, debido a que permite interpretar de manera directa cómo cambia la predicción ante modificaciones en cada variable.

Por lo tanto, la elección entre ambos modelos depende del objetivo de la aplicación. Si la prioridad es minimizar el error de predicción, los resultados obtenidos favorecen claramente a Random Forest. Si, por el contrario, se requiere un modelo sencillo, transparente y fácil de interpretar, la regresión lineal presenta ventajas importantes. Esta diferencia entre precisión e interpretabilidad constituye uno de los principales compromisos al seleccionar un modelo de aprendizaje automático para problemas de predicción energética.

IV. DISCUSIÓN

Los resultados obtenidos indican que, para el conjunto de datos analizado, una regresión lineal múltiple es capaz de capturar una proporción considerable de la relación entre las características geométricas de un edificio y su carga de calefacción. El modelo alcanzó un MAE de 2.18, un RMSE de 3.02 y un R^2 de 0.9124 sobre el conjunto de prueba, lo que indica que aproximadamente el 91.24% de la variabilidad observada en *heating_load* es explicada por el modelo. Este resultado es consistente con los hallazgos obtenidos durante el análisis exploratorio de datos, donde variables como *roof_area* mostraron individualmente un $R^2 \approx 0.74$ con respecto a *heating_load*, proporcionando evidencia inicial de la existencia de relaciones lineales relevantes en el conjunto de datos.

La estabilidad observada en la curva de convergencia del Gradiente Descendente (Figura 1), junto con la similitud entre las métricas obtenidas sobre los conjuntos de entrenamiento y prueba (Tabla VIII), proporciona evidencia de un comportamiento estable durante el proceso de optimización y de una capacidad de generalización consistente. La diferencia entre ambos conjuntos fue reducida, con un $\Delta MAE = 0.11$ y un $\Delta R^2 = 0.0058$, lo que sugiere que el modelo no presenta un sobreajuste significativo. En particular, el desempeño similar entre entrenamiento y prueba indica que el modelo mantiene un nivel de error comparable ante observaciones que no fueron utilizadas para ajustar sus parámetros.

La implementación manual del Gradiente Descendente, incluyendo el cálculo de las predicciones, la función de costo y los gradientes mediante bucles explícitos, mostró un comportamiento coherente con el esperado para un problema de regresión lineal. El costo disminuyó de manera estable durante el entrenamiento y alcanzó una región de estabilización antes de completar las 25,000 iteraciones. Si bien este comportamiento no constituye por sí mismo una demostración formal de la corrección matemática de la implementación, sí proporciona evidencia experimental de que el algoritmo fue capaz de optimizar los parámetros del modelo de manera estable.

No obstante, se observaron errores individuales de mayor magnitud en la región de valores elevados de *heating_load*, particularmente para valores superiores a 35 unidades. Como se observó en la Figura 2, algunas predicciones se alejan de la línea de referencia $y = x$ en esta región. Este comportamiento puede indicar que el modelo lineal presenta dificultades para representar completamente ciertos patrones presentes en las observaciones de mayor demanda térmica. Una posible explicación es la existencia de interacciones o relaciones no lineales entre las variables arquitectónicas que no pueden ser representadas mediante una combinación lineal de los predictores. Sin embargo, esta interpretación debe considerarse como una posible explicación y no como una demostración directa de no linealidad. El análisis de modelos más expresivos podría permitir determinar si estas relaciones adicionales contribuyen a reducir los errores observados.

La incorporación de Random Forest confirmó esta hipótesis de forma experimental. Al utilizar un conjunto de 300 árboles de decisión capaces de modelar particiones no lineales del espacio de características y capturar interacciones complejas, el modelo alcanzó un desempeño sustancialmente superior, logrando un $R^2 = 0.9973$, un MAE de 0.3670 y un RMSE de 0.5324 en el conjunto de prueba (Tabla XIII). Esto representa una reducción del 83.2% en el MAE y del 82.4% en el RMSE en comparación con la regresión lineal (Tabla XIV y Figura 10).

Asimismo, el análisis gráfico de los residuos de Random Forest (Figura 8 y Figura 9) demuestra que la dispersión observada en valores elevados de *heating_load* (> 35 unidades) fue prácticamente eliminada, ajustándose de forma precisa a la diagonal ideal $y = x$ y concentrando la mayoría de los residuos en torno a cero con una

varianza mínima. La reducida brecha entre entrenamiento y prueba ($\Delta MAE = 0.2227$, $\Delta R^2 = 0.0022$) confirma adicionalmente que los mecanismos de *bootstrap aggregation* y selección aleatoria de predictores previnieron el sobreajuste de manera efectiva.

A. Limitaciones

El conjunto de datos utilizado corresponde a simulaciones de edificios con geometrías controladas y, por lo tanto, no representa directamente mediciones obtenidas en edificios reales. Además, las variables disponibles no incorporan información temporal, condiciones climáticas, patrones de ocupación ni otras variables operativas que pueden influir sobre la demanda energética real. En consecuencia, el modelo no debe interpretarse como una herramienta de predicción del consumo energético en tiempo real, sino como un modelo de estimación de la carga de calefacción bajo las condiciones representadas por el conjunto de datos.

Otra limitación corresponde a la naturaleza lineal del modelo empleado inicialmente. La regresión lineal múltiple representa la relación entre las variables mediante una combinación lineal de sus características, por lo que no modela explícitamente interacciones ni relaciones no lineales entre ellas.

Por su parte, la inclusión de Random Forest introduce sus propias limitaciones metodológicas. En primer lugar, se pierde la interpretabilidad directa que ofrece la regresión lineal. Mientras que la regresión lineal proporciona coeficientes θ únicos con un significado físico y una magnitud de efecto marginal constante, Random Forest funciona como un modelo de tipo "caja negra" (*black box*), donde la predicción surge del promedio de 300 árboles divididos por umbrales continuos. Aunque la importancia de variables permite jerarquizar los predictores según su contribución a la reducción de impureza, no indica la dirección lineal del efecto ni ofrece una fórmula analítica cerrada.

En segundo lugar, los modelos basados en árboles de decisión tienen una limitación inherente para extrapolar predicciones fuera del rango de valores de entrada observados durante el entrenamiento ($[y_{\min}, y_{\max}]$). Ante geometrías de edificación o escalas extremas no contempladas en el conjunto de prueba, Random Forest saturará sus predicciones en los valores mínimos o máximos aprendidos en los nodos hoja, a diferencia de la regresión lineal que sí permite extrapolar tendencias cuantitativas (aunque con riesgo de error por no linealidad).

B. Implicaciones prácticas

A pesar de estas limitaciones, la simplicidad e interpretabilidad del modelo de regresión lineal representan una ventaja para aplicaciones en etapas tempranas del diseño arquitectónico. Los coeficientes θ permiten cuantificar la contribución del resto de las variables al mantener constantes las demás características, lo que facilita interpretar la relación entre las variables arquitectónicas y la carga de calefacción. Por su bajo costo computacional y su capacidad para generar predicciones de forma inmediata a partir de las características de un edificio, el modelo lineal puede utilizarse como una herramienta de estimación preliminar durante las primeras etapas del diseño.

Por otro lado, el modelo Random Forest integrado en un *Pipeline* de *scikit-learn* obtuvo un desempeño predictivo elevado dentro del dominio de las configuraciones simuladas incluidas en el conjunto de datos. En particular, el modelo alcanzó un Error Absoluto Medio de 0.3670 unidades de carga de calefacción sobre el conjunto de prueba. Este resultado sugiere que el modelo puede utilizarse como una herramienta de apoyo para explorar y comparar configuraciones arquitectónicas durante etapas preliminares de análisis.

No obstante, estos resultados deben interpretarse dentro del alcance del conjunto *Energy Efficiency*. Dado que los datos provienen de simulaciones con geometrías y condiciones controladas, el desempeño reportado no constituye por sí mismo una validación para edificios reales ni reemplaza una simulación energética detallada cuando esta sea necesaria. rigurosas.

V. CONCLUSIONES

Los resultados obtenidos demuestran que es posible estimar la carga de calefacción de los edificios del conjunto de datos analizado utilizando únicamente sus características arquitectónicas. Sobre el conjunto de

prueba, el modelo de regresión lineal múltiple obtuvo un MAE de 2.18, un RMSE de 3.02 y un $R^2 = 0.9124$, lo que indica que aproximadamente el 91.24% de la variabilidad observada en *heating_load* es explicada por la aproximación lineal.

Uno de los principales objetivos del estudio fue implementar el modelo de regresión lineal desde sus fundamentos matemáticos. Para ello, se desarrollaron manualmente las etapas de preparación de características, la incorporación del intercepto, el cálculo de las predicciones, la función de costo y el gradiente, así como la actualización de los parámetros mediante Gradiente Descendente. El algoritmo fue entrenado durante 25,000 iteraciones con una tasa de aprendizaje de $\alpha = 0.001$, obteniendo una reducción estable de la función de costo hasta alcanzar una región de convergencia. Este comportamiento proporciona evidencia experimental de que el procedimiento de optimización funcionó de manera estable para el problema planteado.

El análisis de los parámetros aprendidos en la regresión lineal también permitió identificar diferencias en la contribución de las variables predictoras. Entre las variables numéricas estandarizadas, *overall_height* presentó el coeficiente positivo de mayor magnitud ($\theta_5 = 7.1220$), mientras que *relative_compactness* presentó un coeficiente negativo ($\theta_1 = -2.0629$). La interpretación de estos coeficientes es consistente con los patrones observados durante el análisis exploratorio y con la interpretación física del problema: las características geométricas del edificio tienen una relación relevante con su carga de calefacción. No obstante, estos coeficientes representan asociaciones dentro del modelo y no deben interpretarse de forma aislada como evidencia de causalidad.

La comparación entre los conjuntos de entrenamiento y prueba mostró además un comportamiento consistente de la regresión lineal. El MAE pasó de 2.0753 en entrenamiento a 2.1814 en prueba, mientras que el R^2 pasó de 0.9182 a 0.9124, sugiriendo un modelo libre de sobreajuste significativo.

Asimismo, la inclusión de un modelo no lineal mediante Random Forest con 300 árboles de decisión permitió abordar la principal limitación observada en el modelo lineal. Random Forest logró un desempeño notablemente superior en prueba, alcanzando un $R^2 = 0.9973$, un MAE de 0.3670 y un RMSE de 0.5324. Esto representa una reducción de más del 83% en el error medio de predicción, demostrando la importancia de capturar las interacciones no lineales presentes entre las características geométricas.

Finalmente, las pruebas de integración demostraron la viabilidad de desplegar ambos modelos sobre nuevas observaciones de entrada mediante pipelines estructurados. Mientras que el *PredictorRegresiónLineal* ofrece rapidez e interpretabilidad directa, el *Pipeline* de *scikit-learn* facilita una estimación precisa y robusta.

En conclusión, este estudio evidencia el compromiso (*trade-off*) fundamental en aprendizaje automático entre la interpretabilidad y la precisión predictiva. La regresión lineal constituye una excelente herramienta para comprender las relaciones físicas fundamentales de forma transparente, mientras que Random Forest se consolida como la alternativa idónea cuando la prioridad principal es la máxima precisión en la estimación energética.

VI. REFERENCIAS

REFERENCES

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Chou, J.-S., & Bui, D.-K. (2014). Modeling heating and cooling loads by artificial intelligence for energy-efficient building design. *Energy and Buildings*, 82, 437–446. <https://doi.org/10.1016/j.enbuild.2014.07.036>
- Hindasi, Y. A., Ilbeigi, M., Tajadod, O. E., Karimi, M., Baitfarhan, M. A., Yavarinoori, S., & Alnejem, M. (2026). Performance driven form finding methodology for energy efficient building design based on energy consumption optimization. *Discover Sustainability*. <https://doi.org/10.1007/s43621-026-03743-3>
- Hong, T., & Fan, S. (2016). Probabilistic electric load forecasting: A tutorial review. *International Journal of Forecasting*.
- Ng, A. (2018). *Machine learning yearning*.

- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>
- Sajjad, M., Khan, S., Khan, N., Haq, I., Ullah, A., Lee, M. Y., & Baik, S. (2020). Towards efficient building designing: Heating and cooling load prediction via multi-output model. *Sensors*, 20(22), 6419. <https://doi.org/10.3390/s20226419>
- Tsanas, A., & Xifara, A. (2012). Accurate quantitative estimation of energy performance of residential buildings using statistical machine learning tools. *Energy and Buildings*.